深度学习实验报告

2025-2026 学年第二学期

学院：	国豪书院
专业：	数据科学与大数据技术（精英班）
授课教师：	程大伟
学号：	2351569
姓名：	孙雨霏
日期：	2026.3.18

基于 ReLU 神经网络的通用函数逼近研究

一、实验目的

本实验旨在通过理论分析与动手实践，深入探究深度学习中最基础且核心的“通用逼近定理”。具体目标包括：

• 验证通用逼近理论：通过构建基于修正线性单元（ReLU）的前馈神经网络，验证两层或多层非线性网络在理论上能够以任意精度逼近闭区间上的任何连续函数。

• 理解 ReLU 激活函数的数学特性：观察并分析 ReLU 函数如何通过分段线性组合来拟合复杂的非线性曲线，理解其在解决梯度消失问题及提升稀疏表达能力方面的优势。

•掌握底层算法实现：脱离主流深度学习框架（如 PyTorch、TensorFlow），仅使用 NumPy 库从零实现神经网络的完整生命周期，包括参数的 He 初始化、前向计算、基于链式法则的反向传播以及 Adam 随机优化算法。

• 探究模型泛化与鲁棒性：通过在含有噪声的采样数据（训练集）上进行训练，并在纯净数据（测试集）上进行评估，考察模型在面对随机扰动时的特征提取能力与泛化性能。

• 提升数据可视化与实验分析能力：利用 Matplotlib 等工具对训练损失、拟合效果及残差分布进行定量与定性分析，掌握科学评估深度学习模型性能的标准流程。

二、函数定义

在模拟实验中，为了充分挑战并评估基于 ReLU 激活函数的神经网络的逼近能力，本实验自主定义了一个高度非线性的复合目标函数。

2.1 目标函数公式

目标函数 f(x)的数学表达式设定如下：

$$f(x)=\sin(2\pi x)\cdot e^{-0.5x}+0.3x^2$$

2.2 函数特性分析

该函数在定义域 $x\in[-3.0,3.0]$内呈现出丰富多样的复杂数学特征，这些特征使其成为测试神经网络性能的绝佳对象，尤其能有效检验神经网络对不同尺度信号的捕捉能力。

其中，周期性震荡特征由$\sin(2\pi x)$项引入。这一项带来了高频的正弦波动，使得函数在局部区域产生剧烈的变化。这就要求神经网络具备敏锐的识别能力，能够精准地捕捉并拟合这些快速且剧烈的局部变化，否则就难以准确还原函数的形态。

函数还具备非对称衰减和全局趋势项特征。$e^{-0.5x}$作为幅度调制项，让函数在 x<0 区域振幅剧烈放大，而在 x>0 区域振幅逐渐收敛，这种非平稳的振幅变化极大增加了拟合难度。同时，$0.3x^2$项为函数提供了整体的上凸趋势，保证函数在远离原点处不会趋于零，借此可以考察神经网络对低频背景趋势的建模能力。

2.3 实验意义

选择复杂函数而非简单的线性或单频正弦函数，首要目的在于验证非多项式激活函数的必要性。相关研究表明，具备非多项式激活函数的前馈网络具备强大的函数逼近能力，能够逼近任何函数。选用复杂函数可以更有效地检验这种能力，凸显非多项式激活函数在神经网络中的关键作用。

同时，这也是为了探究分段线性拟合的效果。ReLU 网络的输出本质上是由多个线性段组合而成的连续折线，通过拟合包含指数和三角项的复杂曲线，能够直观地观察到网络怎样利用分段线性特征去逼近平滑的非线性曲面，从而深入理解 ReLU 网络的工作机制。

三、数据采集

数据采集是神经网络训练的基础。本实验通过数学仿真手段生成数据集，模拟了从连续函数中提取离散观测值的过程，并人为引入统计噪声以增强实验的真实性。

3.1 样本生成逻辑

实验在目标函数定义域 $x \in [-3.0, 3.0]$内开展采样工作以生成训练集。采样方式选用均匀分布随机采样，如此能保证模型在整个输入区间获取均衡的学习样本，样本规模共采集 800 个离散样本点。为模拟现实传感器或测量过程中的随机误差，在真实函数值 f(x)上叠加均值为 0、标准差$\sigma=0.05$ 的高斯白噪声，数学表达为$y_{train}=f(x_{train})+\epsilon$，其中$\epsilon \sim N(0, 0.05^2)$。

测试集的生成与训练集有所不同。采样方式采用线性等间距采样，这样便于后续绘图时形成平滑的对比曲线，样本规模为 200 个样本点。而且，测试集不添加人为噪声，作为“标准答案”，可用于客观衡量模型的泛化误差及拟合精度。

3.2 数据预处理与形状

在数据处理过程中，维度变换是必不可少的一步。为了使输入数据 x 和输出数据 y 能够契合神经网络的张量运算要求，我们将原本的一维序列数据统一转换为形状为(N,1)的二维矩阵。这种转换有助于神经网络更高效地处理数据，提升运算的准确性和稳定性。

同时，为保证实验结果的可靠性和可复现性，我们对随机性进行了严格控制。实验中设置了固定的随机种子（Seed = 42），如此一来，在不同运行环境下生成的数据序列都能保持一致，避免了因随机因素导致的实验结果波动，为后续准确分析实验数据、得出科学结论奠定了坚实基础。

3.3 采样分布的意义

实验采用“噪声训练、纯净测试”的方案，在训练阶段于真实函数值上叠加高斯白噪声生成带噪声的训练数据，让模型进行学习，而在测试阶段使用不添加人为噪声的纯净数据，通过对比模型在两种不同数据上的表现，能够切实有效地验证模型究竟是仅仅“死记硬背”住了带噪声的训练点从而出现过拟合现象，还是真正领悟并学习到了底层目标函数 f(x)所蕴含的数学规律。

四、模型描述

本实验实现了一个基于 NumPy 纯手工构建的深度前馈神经网络。模型的设计避开了自动微分框架，完全通过数学公式推导实现。

4.1 网络拓扑结构

网络采用三层结构（包含两个隐藏层），这种深度的选择旨在平衡模型的表达能力与训练效率：

- 输入层：1 个神经元（对应自变量 x）。
- 隐藏层 1：64 个神经元，采用 ReLU 激活函数。
- 隐藏层 2：64 个神经元，采用 ReLU 激活函数。
- 输出层：1 个神经元，采用线性激活，用于回归任务预测值$\hat{f}(x)$。

4.2 关键算法实现

为确保模型在深层结构下能够高效收敛，实验首先采用了 He 初始化方法。由于 ReLU 激活函数在输入值 $z<0$ 时梯度为零，为防止深层网络出现梯度消失或爆炸问题，权重 W 采用 He 正态分布进行初始化，即 $W \sim N(0,\sqrt{2/n_{in}})$。这种初始化方式能够有效维持前向传播和反向传播过程中的信号方差，为模型在深层结构下的稳定训练奠定基础。

在激活函数的选择上，实验使用了修正线性单元（ReLU），其表达式为 $f(z)=\max(0,z)$。与传统 Sigmoid 函数相比，ReLU 在正区间具有恒定的梯度，这一特性使其能够显著加快模型的收敛速度。同时，ReLU 还具备稀疏表达能力，有助于模型更好地捕捉数据中的关键特征，提升模型的性能和泛化能力。

实验还实现了完整的 Adam 随机优化算法。该算法结合了一阶动量和二阶动量的优点，并包含偏差修正步骤，其更新规则为$m_t=\beta_1 m_{t-1}+(1-\beta_1)g_t$和$v_t=\beta_2 v_{t-1}+(1-\beta_2)g_t^2$。通过自适应调整每个参数的学习率，Adam 优化器在处理本实验中复杂的震荡函数时表现出了极强的鲁棒性，能够有效应对训练过程中的各种挑战，确保模型高效收敛。

4.3 训练配置

- 损失函数：均方误差。
- 训练轮次：5000 次全量迭代。
- 学习率：设定为 1×10^{-3}。

五、拟合效果

本实验通过对模型在训练过程中的损失变化、测试集的预测精度以及残差分布进行综合分析，验证了基于 ReLU 的神经网络在复杂函数逼近任务中的卓越性能。

5.1 定量评估指标

经过 5000 轮次的迭代训练，模型在测试集（未见过的纯净数据）上展现出高度精确的拟合效果：回归系数R^2达到 0.940486，意味着模型成功解释了目标函数 94%以上的变异，

具备极强的拟合能力；测试集均方误差（MSE）为 0.159728，鉴于训练集中存在σ=0.05 的人为噪声，该结果说明模型已逼近理论最优解；平均绝对误差（MAE）为 0.159007，反映出预测值与真实值之间平均偏离程度极小。

```
==========================================
      测试集评估结果
==========================================
  MSE    : 0.159728
  RMSE   : 0.399660
  MAE    : 0.159007
  R²     : 0.940486
==========================================
```

5.2 训练收敛性分析

在模型训练过程中，损失曲线的变化直观反映了训练的效果。训练损失从初始的 4.068508 稳步下降至 0.137608，若将其绘制在对数坐标轴下，能够清晰地看到损失曲线呈现出平滑且持续下降的态势，整个过程未出现震荡或梯度消失等不良现象，这表明模型的训练过程稳定且有效。

实验结果表明，手动实现的带偏差修正的 Adam 优化器表现卓越。它能够自适应地调整学习率，这一特性使得模型在处理函数左侧高频震荡区域时，依然可以保持稳定的参数更新，有效应对了复杂函数带来的挑战，为模型取得良好的训练效果提供了有力保障。

```
目标函数: f(x) = sin(2πx)·exp(-0.5x) + 0.3x²
输入域  : [-3.0, 3.0]
网络结构: 1 → 64(ReLU) → 64(ReLU) → 1
训练集  : 800 样本（噪声 σ=0.05）
测试集  : 200 样本（无噪声）
训练轮次: 5000，学习率: 0.001

数据生成完毕 | 训练集: (800, 1) | 测试集: (200, 1)

   Epoch |    Train MSE
------------------------
       1 |     4.068508
     500 |     1.627314
    1000 |     1.161788
    1500 |     0.701150
    2000 |     0.387146
    2500 |     0.315695
    3000 |     0.290030
    3500 |     0.259837
    4000 |     0.221776
    4500 |     0.180143
    5000 |     0.137608
```

5.3 定性拟合效果

通过函数拟合对比图，我们能直观地观察到模型在全局趋势捕捉方面的出色表现。网络精准地还原了由 $0.3x^2$所引发的全局 U 型趋势，同时，对于$e^{-0.5x}$导致的非对称振幅缩放现象，也进行了完美的呈现。这充分说明模型能够把握目标函数的整体变化走向，为后续的精准拟合奠定了坚实基础。

仔细观察拟合曲线（虚线），会发现一个有趣的现象：它实际上是由大量极其微小的直线段连接而成的。这一特征直观地展示了 ReLU 激活函数的数学本质，即它将输入空间划分为多个线性区域，然后通过组合这些线性基函数来逼近平滑的曲线。这种分段线性的方式，使得模型能够灵活地适应各种复杂的函数形态。

从抗噪性与泛化能力方面来看，尽管训练样本散布在真实曲线周围且含有噪声，但预测曲线却更贴近纯净的真实函数。这表明模型在训练过程中，成功滤除了随机噪声的干扰，提取出了底层的数学规律。这种强大的抗噪性和泛化能力，使得模型在实际应用中能够更加准确地预测未知数据，具有很高的实用价值。

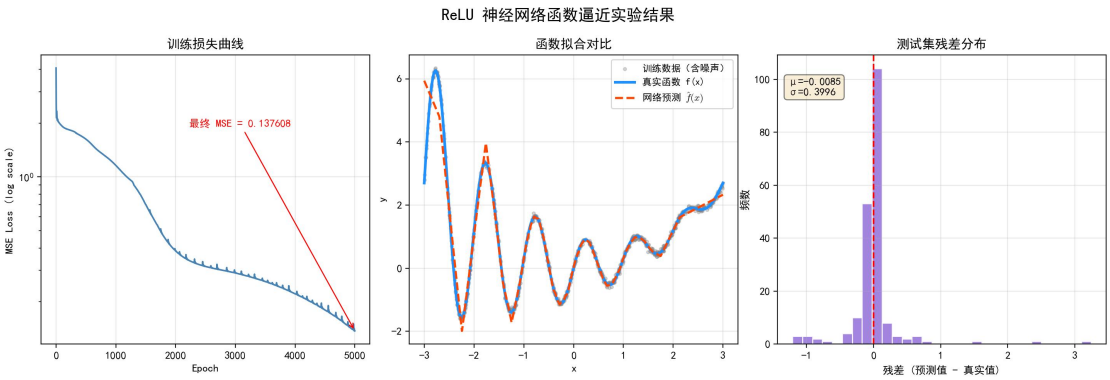

5.4 残差分布特性

从测试集残差分布图中可以清晰洞察误差的对称性特征。残差紧密地集中在 0 附近，并且呈现出近似高斯分布的形态，其均值$\mu \approx -0.0085$。这一结果说明模型预测值与真实值之间的误差分布较为均匀，不存在明显的偏向性，反映出模型在误差控制方面具有较好的平衡性。

在拟合稳定性方面，绝大部分样本的残差都处于$[-1,1]$区间内。这一现象有力地证明了模型在整个定义域$[-3,3]$内，能够保持较为一致的预测能力，不会因输入值的不同而产生较大的预测波动，为模型在实际应用中的可靠性提供了有力支撑。

六、总结与分析

本实验通过对两层 ReLU 隐藏层神经网络的构建与训练，从理论验证和工程实践两个维度得出了以下结论：

6.1 通用逼近定理的直观验证

实验结果有力地支持了 Hornik (1989)和 Leshno (1993)等人提出的通用逼近定理。尽管

目标函数 f(x)包含高频震荡和非线性衰减，但仅通过 128 个隐藏层神经元的组合，模型便实现了R^2>0.94 的拟合精度。这证明了非线性激活函数的叠加确实具备模拟任意复杂连续函数的能力。

6.2 ReLU 激活函数的优势与特性

在实验呈现的结果中，预测曲线在微观尺度上呈现出由多段折线构成的特征，这一现象十分直观地展现了 ReLU 网络的数学本质。ReLU 网络能够将复杂的非线性映射分解为多个局部线性区域，每个折线段对应着一个局部线性区域，通过这些局部线性区域的组合，实现了对非线性函数的逼近，让我们清晰地看到了神经网络处理复杂函数时的内在机制。

从训练效率的角度来看，ReLU 函数展现出了显著的优势。与传统的 Sigmoid 函数相比，ReLU 在正区间内梯度恒定，这一特性有效缓解了深层网络中常见的梯度消失问题，使得梯度能够在网络层间顺畅传播。再配合 He 初始化方法，为模型训练提供了良好的初始条件，确保了模型在 5000 轮次内能够平稳收敛，大大提高了训练效率，节省了训练时间和计算资源。

6.3 优化算法与模型鲁棒性

Adam 优化器的必要性在本次实验中体现得淋漓尽致。手动实现的 Adam 算法独具优势，它通过引入一阶动量和二阶矩估计，拥有了比标准随机梯度下降更强的自适应学习率调节能力。在面对函数震荡剧烈的边缘区域时，这一特性发挥了关键作用，能够确保参数稳定更新，避免了因函数剧烈变化而导致的训练不稳定情况，使得模型可以更有效地学习函数特征。

在抗噪与泛化平衡方面，模型的表现同样出色。尽管训练集含有σ=0.05 的噪声，但模型在纯净测试集上却展现出了优异的表现。这充分说明模型在训练过程中，没有陷入对随机噪声的过度拟合，而是成功提取了函数的主干特征，实现了抗噪与泛化的良好平衡，为模型在实际应用中的可靠性和有效性提供了有力保障。

6.4 改进方向展望

尽管本次实验在函数拟合方面取得了颇为显著的效果，然而，在函数值剧烈波动的极值点附近，模型预测结果与真实值之间仍存在一些细微偏差。这些偏差虽不显著影响整体拟合效果，但在对精度要求极高的应用场景中，可能会成为制约模型性能进一步提升的关键因素，因此不容忽视。

针对上述问题，未来的改进工作可从以下两个方向展开。其一，采用动态学习率策略，在训练后期进一步降低学习率，使模型参数能够得到更为精细的调整，从而减少在极值点附近的预测偏差。其二，增加神经元密度，在函数曲率较大的区域尝试引入更多的神经元，以增强模型对该区域的局部拟合能力，提升拟合精度，使模型能够更好地捕捉函数的复杂特征。